SEO Automation Tool — Blueprint Pengembangan (Go)

> **Nama kode:** `seo-boost` **Stack:** Go (standard library first) · 1 binary · CLI dulu, Web UI lokal menyusul **Prinsip:** *Ponytail* — bangun versi paling tipis yang benar-benar jalan. Tanpa framework, tanpa ORM, tanpa dependency yang bisa dihindari. **Biaya:** Rp 0. Tanpa trial, tanpa kartu kredit, tanpa langganan.

Daftar Isi

0. Ringkasan Eksekutif
1. Tujuan, Non-Goals, dan Batasan Jujur
2. Prasyarat & Setup Google (Gratis)
3. Arsitektur
4. Keputusan Stack & Dependency
5. Struktur Project
6. Spesifikasi CLI
7. Konfigurasi
8. Data Model & Penyimpanan
9. Spesifikasi Modul (Detail)
10. Contoh Output
11. Keamanan
12. Strategi Testing
13. Build & Distribusi
14. Otomasi / Scheduling
15. Roadmap & Checklist per Fase
16. Ponytail Debt Ledger
17. Troubleshooting & FAQ
18. Lampiran: Referensi API

0. Ringkasan Eksekutif

`seo-boost` adalah tool **eksternal** (berjalan di luar website) yang menjawab 4 pertanyaan SEO, memakai **data resmi Google Search Console (GSC)**:

#	Pertanyaan	Sumber data	Endpoint
1	Apakah semua halaman sudah **di-crawl** Google?	GSC URL Inspection API	`urlInspection/index:inspect`
2	Apakah halaman sudah **ter-index**?	GSC URL Inspection API	`urlInspection/index:inspect`
3	Apakah **tayang di halaman 1** Google, dan di kata kunci apa?	GSC Search Analytics API	`searchAnalytics/query`
4	Kata pencarian mana yang **belum ada di teks halaman**?	Search Analytics + crawler HTML sendiri	gabungan

Karena hanya bergantung pada **URL + HTML +** `sitemap.xml`, tool ini **universal**: Laravel, Next.js, Go, Python, HTML statis, WordPress, semuanya sama di mata tool.

Target akhir: satu file `seo-boost` (atau `seo-boost.exe`), kira-kira 8–12 MB, RAM sekitar 15–30 MB saat crawl, siap dicopy ke laptop, VPS, atau CI.

1. Tujuan, Non-Goals, dan Batasan Jujur

1.1 Tujuan (In Scope)

- Multi-site dalam satu konfigurasi.
- Menemukan semua URL (dari `sitemap.xml`, sitemap index, atau spidering internal link).
- Status crawl dan index per URL, dengan riwayat perubahan.
- Performa pencarian per halaman dan per query: clicks, impressions, CTR, posisi.
- Penanda "tayang di halaman 1" (posisi rata-rata ≤ 10).
- Analisis kesenjangan kata kunci (*keyword gap*) antara query Google dan isi halaman.
- Audit SEO on-page dasar: title, meta description, H1, canonical, robots meta, JSON-LD, alt gambar.
- Submit sitemap otomatis dan ping IndexNow (Bing/Yandex dkk).
- Laporan: terminal, JSON, Markdown, HTML.

1.2 Non-Goals (Sengaja TIDAK Dibuat)

Tidak dibuat	Alasan
Scraping halaman hasil Google (SERP)	Melanggar ToS Google, kena CAPTCHA, tidak stabil. Posisi dari GSC sudah resmi.
Google Indexing API **sebagai fitur default**	Resminya hanya untuk `JobPosting` dan `BroadcastEvent`. Untuk blog biasa **tidak didukung resmi** dan efeknya tidak terjamin. Tersedia sebagai fitur **opt-in** yang mati secara default (lihat 9.7.3).
Cek ranking untuk situs milik orang lain	GSC hanya memberi data untuk properti yang **kamu miliki / punya akses**.
Backlink / domain authority	Butuh data berbayar (Ahrefs/Semrush). Tidak gratis.
Rendering JavaScript (headless browser)	Menambah dependency berat. Lihat Debt Ledger.
Database server / ORM	File JSON sudah cukup untuk skala portofolio dan blog.

1.3 Batasan Data yang HARUS Dipahami

> **IMPORTANT**
>
> Bagian ini menentukan kejujuran laporan. Jangan dilewati.

Hal	Kenyataan
"Posisi" bukan posisi pasti	`position` di GSC adalah **rata-rata** posisi di semua impresi (beda lokasi, perangkat, waktu). Posisi 4.5 berarti rata-rata, bukan "selalu #4". "Halaman 1" = `position ≤ 10` adalah **pendekatan**.
Data GSC tertunda	Biasanya 2–3 hari. Data hari ini belum ada. Riwayat maksimal **16 bulan**.
Query dianonimkan	Query yang sangat jarang (privasi) tidak muncul. Total klik per query bisa kurang dari total klik halaman.
Kuota URL Inspection	**2.000 URL/hari/properti** dan **600 request/menit/properti**. Situs besar harus dirotasi (ada penjadwal kuota, lihat 9.4).
URL Inspection = status terindeks, bukan "request indexing"	URL Inspection API hanya **membaca** status. Tombol "Request Indexing" di UI GSC **tidak punya API**. Plugin WordPress juga tidak memakai tombol itu; mereka memakai Google Indexing API (lihat 9.7.3).
"Request indexing" tidak menjamin ter-index	Baik tombol di GSC maupun Indexing API hanya meminta Google **mengunjungi (crawl)** URL. Apakah URL lalu di-index tetap bergantung pada kualitas konten.
`coverageState` adalah teks bebas	Teks seperti `"Crawled - currently not indexed"` bisa berubah wording. Tool memetakan berdasarkan `verdict` dulu, lalu pencocokan teks, lalu fallback tampilkan teks mentah.
IndexNow tidak mencakup Google	IndexNow didukung Bing, Yandex, Naver, Seznam, dkk. **Google tidak ikut.** Untuk Google, cara resminya adalah sitemap dan internal link yang baik.
IndexNow butuh file kunci di situs	File `https://domain/<key>.txt` harus bisa diakses publik. Ini satu-satunya "sentuhan" ke website.
Crawler kita ≠ Googlebot	Kita mengambil HTML mentah. Halaman yang isinya dirender JS (SPA) akan terlihat tipis di crawler kita walau Google bisa merendernya. Tool memberi peringatan.
Rekomendasi kata ≠ jaminan ranking	"Kata bocor" adalah **peluang berbasis data**, bukan jaminan naik peringkat.

2. Prasyarat & Setup Google (Gratis)

2.1 Software

Kebutuhan	Versi	Catatan
Go	**1.22+**	Butuh `net/http` routing pattern baru, `log/slog`, `embed`. Unduh di https://go.dev/dl/
Git	bebas	Opsional
Akun Google	bebas	Yang sama dengan pemilik GSC

Cek instalasi:

```
powershell
go version     # harus go1.22 atau lebih baru
```

2.2 Setup Google Cloud (tanpa billing)

> NOTE
>
> Search Console API **gratis dan tidak memerlukan billing aktif**. Jangan klik "Activate / Upgrade" kalau Google menawarkan trial. Itu tidak diperlukan.

1. Buka https://console.cloud.google.com/ lalu **New Project** (misal: `seo-boost`).
2. Menu **APIs & Services** → **Library** → cari **"Google Search Console API"** → **Enable**.
3. Menu **APIs & Services** → **Credentials** → **Create Credentials** → **Service account**.
    - Nama: `seo-boost-bot`. Role: **kosongkan** (tidak perlu role GCP).
4. Buka service account yang baru dibuat → tab **Keys** → **Add key** → **Create new key** → **JSON**. File JSON terunduh.
5. Simpan ke `secrets/sa.json` (**jangan commit ke Git**).
6. Catat `client_email` di dalam JSON, bentuknya `seo-boost-bot@seo-boost-123.iam.gserviceaccount.com`.

2.3 Beri Akses di Search Console

1. Buka https://search.google.com/search-console → pilih properti.

2. **Settings** → **Users and permissions** → **Add user**.
3. Isi `client_email` dari langkah 2.2.
4. Permission:

Fitur yang ingin dipakai	Permission minimum
Hanya baca (inspect + analytics)	**Restricted**
Submit sitemap	**Full** (atau Owner)
Google Indexing API (opsional, 9.7.3)	**Owner**

2.4 Jenis Properti (PENTING)

Tipe properti	Format `gsc_property` di config
Domain property	`sc-domain:example.com`
URL-prefix property	`https://example.com/` (**wajib trailing slash, dan sama persis** dengan yang terdaftar)

Kesalahan format ini adalah penyebab #1 error `403 / permission`. Perintah `seo-boost doctor` akan memeriksanya.

3. Arsitektur

3.1 Diagram Komponen

3.2 Alur Data Satu Kali `seo-boost run`

3.3 Prinsip Desain

1. **Satu binary, satu proses.** Tanpa daemon bawaan. Penjadwalan diserahkan ke Task Scheduler, cron, atau GitHub Actions.

2. **Stateless kecuali folder `data/`.** Hapus `data/` = mulai dari nol, tidak ada yang rusak.
3. **Fail-soft per URL.** Satu URL error tidak menghentikan seluruh run. Error dicatat di laporan.
4. **Hemat kuota.** Jangan menginspeksi ulang URL yang statusnya baru dicek, kecuali dipaksa (`--force`).
5. **Output deterministik.** Input sama menghasilkan laporan sama (urutan diurutkan), supaya diff antar run bermakna.

4. Keputusan Stack & Dependency

4.1 Pemakaian Standard Library

Kebutuhan	Paket stdlib	Catatan
HTTP client / server	`net/http`	Timeout wajib diset manual
HTTPS / TLS	`crypto/tls` (otomatis)	Tanpa konfigurasi
JSON	`encoding/json`	
XML (sitemap)	`encoding/xml`	
Sitemap `.gz`	`compress/gzip`	
Tanda tangan JWT RS256	`crypto/rsa`, `crypto/sha256`, `crypto/x509`, `encoding/pem`	Login service account **tanpa library Google**
CLI subcommand	`flag` (`flag.NewFlagSet`)	Tanpa cobra
Concurrency	goroutine, `sync`, `context`	Worker pool dengan channel
Rate limit	`time.Ticker`	Tanpa `x/time/rate`
Logging	`log/slog`	
Tabel terminal	`text/tabwriter`	
Web UI	`embed` + `html/template` + `net/http`	Satu HTML, tanpa framework JS
Hash / ID	`crypto/sha256`, `hash/fnv`	
Test	`testing`, `net/http/httptest`	

4.2 Satu-satunya Dependency: `golang.org/x/net/html`

> WARNING
>
> **Koreksi atas klaim sebelumnya:** stdlib Go **tidak memiliki parser HTML**. Jadi "0 dependency mutlak" tidak 100% mungkin kalau kita ingin mengekstrak `<title>`, `<h1>`, `<meta>`, dan `<a href>` dengan benar.

Opsi	Kelebihan	Kekurangan	Keputusan
A. `golang.org/x/net/html`	Dikelola tim Go sendiri. Tokenizer standar HTML5. **Tidak punya dependency turunan** (hanya stdlib dan subpaket `html/atom` dalam modul yang sama).	Tetap kode pihak luar (pernah ada CVE, misalnya `CVE-2023-3978`, `CVE-2024-45338`).	**DIPILIH**
B. Regex di stdlib	0 dependency	Rapuh pada HTML tidak valid, atribut multi-baris, komentar, `<script>`.	Hanya fallback darurat
C. `goquery` / `colly`	Enak dipakai	Menarik `cascadia`, `net/html`, dll. Melanggar semangat Ponytail.	Ditolak

Mitigasi risiko untuk opsi A:

1. **Pin versi** dan commit `go.sum`.
2. `go mod vendor` supaya build tidak bergantung pada jaringan, dan kode terlihat saat code review.
3. Jalankan `govulncheck ./...` sebelum rilis dan di CI (alat resmi tim Go, tidak masuk ke binary).
4. Update `x/net` setiap ada advisory.

```
powershell
go install golang.org/x/vuln/cmd/govulncheck@latest
govulncheck ./...
```

> `// ponytail:` Memakai `x/net/html` karena stdlib tak punya parser HTML. Batas: satu dependency. Jalur upgrade/keluar: tulis tokenizer mini sendiri (~150 baris) bila ingin 0 dependency.

4.3 Perbandingan Stack Final (untuk Dokumentasi)

Aspek	Go (dipilih)	Python stdlib	Deno	Rust
RAM	~15–30 MB	~30–45 MB	~60–90 MB	~5–15 MB
Dependency wajib	1 (`x/net/html`)	0–1	0	puluhan–ratusan crate
Distribusi	1 binary	Perlu interpreter	Perlu runtime/compile	1 binary
RSA-sign bawaan	Ya	Tidak	Ya (WebCrypto)	Tidak
Parser HTML bawaan	Tidak	Ya	Tidak	Tidak
Concurrency	Sangat mudah	Sedang	Mudah	Sulit (async)

5. Struktur Project

Struktur **datar** (`package main`) sengaja dipilih. Ini cukup sampai kira-kira 3.000 baris. Lihat Debt Ledger untuk saat pecah ke `internal/`.

```
seo-boost/
├─ go.mod
├─ go.sum
├─ vendor/                     # hasil `go mod vendor` (opsional tapi disarankan)
├─ SEO_Automation_Tool_Development.md
├─ README.md
├─ config.example.json
├─ .gitignore                  # secrets/, data/, config.json, *.exe
│
├─ main.go                     # entry point + dispatch subcommand
├─ config.go                   # load + validasi config
├─ google.go                   # auth JWT + helper HTTP ke Google API
├─ gsc.go                      # inspect, searchAnalytics, sitemaps, sites.list
├─ sitemap.go                  # parse sitemap/sitemap index/.gz
├─ crawl.go                    # fetch halaman + worker pool + spider
├─ extract.go                  # ekstrak title/meta/h1-h3/teks/link/jsonld (x/net/html)
├─ analyze.go                  # tokenizer kata, keyword gap, audit, opportunity
├─ inspect.go                  # penjadwal kuota + klasifikasi status index
├─ indexnow.go                 # ping IndexNow
├─ store.go                    # baca/tulis JSON atomik + riwayat
├─ report.go                   # renderer text/json/md/html + diff
├─ serve.go                    # Web UI lokal (Phase 3)
├─ notify.go                   # Telegram/Discord webhook (Phase 3)
├─ web/
│  └─ index.html               # template UI (di-embed)
│
├─ *_test.go                   # unit test per file
├─ testdata/                   # fixture sitemap, HTML, respons API
└─ .github/workflows/seo.yml   # contoh otomasi (opsional)
```

6. Spesifikasi CLI

Format: `seo-boost <perintah> [flag]`

Perintah	Fungsi	Flag utama
`doctor`	Cek config, kredensial, akses tiap properti GSC, dan versi Go	`--config`
`discover`	Temukan semua URL situs (sitemap, fallback spider) dan tampilkan selisih sitemap vs link internal	`--site`, `--spider`, `--max-pages`
`crawl`	Ambil HTML semua URL dan ekstrak data on-page + audit	`--site`, `--concurrency`
`inspect`	Cek status crawl/index tiap URL via GSC	`--site`, `--force`, `--limit`, `--only-problems`
`perf`	Tarik clicks/impressions/ctr/position	`--site`, `--days`, `--min-impressions`
`gap`	Analisis keyword gap (query Google vs teks halaman)	`--site`, `--url`, `--top`
`submit`	Submit sitemap ke GSC, ping IndexNow, dan (opsional) Google Indexing API	`--site`, `--indexnow`, `--gsc`, `--google-indexing`
`run`	Gabungan: discover → crawl → inspect → perf → gap → report	`--site`, `--format`, `--out`, `--notify`
`report`	Render ulang laporan dari data tersimpan (tanpa panggil API)	`--site`, `--format`, `--diff`
`serve`	Web UI lokal	`--addr` (default `127.0.0.1:8080`)
`version`	Tampilkan versi	

Flag Global

```
--config   path ke config.json (default: ./config.json)
--site     nama site di config ("all" = semua site)
--format   text | json | md | html  (default: text)
--out      tulis laporan ke file
--verbose  log detail (slog level debug)
```

Exit Code (untuk CI)

Kode	Arti
`0`	Sukses, tidak ada masalah kritis
`1`	Error runtime (config salah, jaringan, auth)
`2`	Sukses, tetapi ditemukan masalah (mis. ada halaman `Blocked` / `Error`, atau ada halaman penting tidak ter-index). Dapat dipakai `--fail-on-issues`

7. Konfigurasi

`config.json` (salin dari `config.example.json`):

```
json
{
  "service_account_file": "./secrets/sa.json",
  "data_dir": "./data",

  "defaults": {
    "user_agent": "seo-boost/1.0 (owner-tool; +https://example.com/about)",
    "crawl_concurrency": 5,
    "crawl_delay_ms": 200,
    "crawl_timeout_s": 20,
    "max_pages": 5000,
    "inspect_rpm": 300,
    "inspect_daily_budget": 1800,
    "reinspect_after_days": 7,
    "perf_days": 28,
    "stopwords": ["id", "en"]
  },

  "sites": [
    {
      "name": "portfolio",
      "gsc_property": "sc-domain:example.com",
      "base_url": "https://example.com",
      "sitemaps": ["https://example.com/sitemap.xml"],
      "exclude_paths": ["/admin", "/tag/", "/search"],
      "priority_paths": ["/", "/blog/"],
      "indexnow_key": ""
    }
  ],

  "notify": {
    "telegram_token_env": "SEOBOOST_TG_TOKEN",
    "telegram_chat_id": "",
    "discord_webhook_env": "SEOBOOST_DISCORD"
  }
}
```

Aturan Validasi (`config.go`)

Field	Aturan
`service_account_file`	File ada, JSON valid, punya `client_email`, `private_key`, `token_uri`
`sites[].name`	Unik, hanya `[a-z0-9-_]` (dipakai jadi nama folder)
`gsc_property`	Diawali `sc-domain:` atau `http(s)://` + berakhiran `/`
`base_url`	Skema http/https, tanpa path
`inspect_daily_budget`	≤ 2000 (batas Google). Default sengaja 1800 untuk sisa ruang manual
`inspect_rpm`	≤ 600
Secret (token)	**Hanya via env var**, tidak boleh langsung di file config

8. Data Model & Penyimpanan

8.1 Tipe Utama

```
go
// Status index yang sudah dinormalisasi (dipetakan dari verdict + coverageState).
type IndexStatus string

const (
        StatusIndexed              IndexStatus = "indexed"
        StatusCrawledNotIndexed    IndexStatus = "crawled_not_indexed"
        StatusDiscoveredNotIndexed IndexStatus = "discovered_not_indexed"
        StatusUnknownToGoogle      IndexStatus = "unknown_to_google"
        StatusBlocked              IndexStatus = "blocked"    // robots.txt / noindex
        StatusError                IndexStatus = "error"      // 404 / 5xx / soft 404 /
redirect error
        StatusDuplicate            IndexStatus = "duplicate"  // canonical lain dipilih
        StatusOther                IndexStatus = "other"      // tampilkan RawCoverage
        StatusNeverInspected       IndexStatus = "never_inspected"
)

type Page struct {
        URL        string    `json:"url"`
        Path       string    `json:"path"`
        InSitemap  bool      `json:"in_sitemap"`
        InternalIn int       `json:"internal_links_in"` // jumlah link internal yang
menunjuk ke sini
        Crawl      *CrawlInfo   `json:"crawl,omitempty"`
        Index      *IndexInfo   `json:"index,omitempty"`
        Perf       *PagePerf    `json:"perf,omitempty"`
        Gaps       []QueryGap   `json:"gaps,omitempty"`
        Audit      []AuditIssue `json:"audit,omitempty"`
}

type CrawlInfo struct {
        FetchedAt   time.Time `json:"fetched_at"`
        HTTPStatus  int       `json:"http_status"`
        FinalURL    string    `json:"final_url"`
        Title       string    `json:"title"`
        MetaDesc    string    `json:"meta_description"`
        Canonical   string    `json:"canonical"`
        RobotsMeta  string    `json:"robots_meta"`
        H1          []string  `json:"h1"`
        H2H3        []string  `json:"h2_h3"`
        WordCount   int       `json:"word_count"`
```

```
        ImagesNoAlt int       `json:"images_no_alt"`
        HasJSONLD   bool      `json:"has_jsonld"`
        ThinHTML    bool      `json:"thin_html"` // diduga SPA/JS-rendered
        Zones       Zones     `json:"-"`         // teks per zona, tidak disimpan (hemat
ruang)
        Err         string    `json:"error,omitempty"`
}

type IndexInfo struct {
        InspectedAt   time.Time   `json:"inspected_at"`
        Status        IndexStatus `json:"status"`
        Verdict       string      `json:"verdict"`        // PASS / PARTIAL / FAIL /
NEUTRAL
        RawCoverage   string      `json:"raw_coverage"`   // coverageState asli dari Google
        LastCrawlTime *time.Time  `json:"last_crawl_time,omitempty"`
        CrawledAs     string      `json:"crawled_as"`     // DESKTOP / MOBILE
        PageFetch     string      `json:"page_fetch_state"`
        RobotsTxt     string      `json:"robots_txt_state"`
        IndexingState string      `json:"indexing_state"`
        GoogleCanon   string      `json:"google_canonical"`
        UserCanon     string      `json:"user_canonical"`
}

type PagePerf struct {
        Clicks      float64 `json:"clicks"`
        Impressions float64 `json:"impressions"`
        CTR         float64 `json:"ctr"`
        Position    float64 `json:"position"` // rata-rata
        Page1       bool    `json:"page1"`    // position <= 10 (pendekatan)
        Queries     []QueryPerf `json:"queries"`
}

type QueryPerf struct {
        Query       string  `json:"query"`
        Clicks      float64 `json:"clicks"`
        Impressions float64 `json:"impressions"`
        CTR         float64 `json:"ctr"`
        Position    float64 `json:"position"`
}

type MatchLevel string

const (
        MatchExact   MatchLevel = "exact"     // frasa utuh ada di teks
        MatchAllWord MatchLevel = "all_words" // semua kata ada tapi tidak berurutan
        MatchPartial MatchLevel = "partial"   // sebagian kata hilang
        MatchAbsent  MatchLevel = "absent"    // tidak ada sama sekali
```

```
)

type QueryGap struct {
        QueryPerf
        Match      MatchLevel `json:"match"`
        FoundIn    []string   `json:"found_in"`    // title, h1, h2h3, meta, body, url, alt
        MissingTok []string   `json:"missing_tokens"`
        Score      float64    `json:"opportunity_score"`
}

type AuditIssue struct {
        Code     string `json:"code"`     // contoh: title_too_long
        Severity string `json:"severity"` // error | warn | info
        Detail   string `json:"detail"`
}
```

8.2 Layout Folder `data/`

```
data/
└─ <site-name>/
   ├─ pages.json                # snapshot terbaru: []Page (gabungan semua modul)
   ├─ inspections.json          # cache hasil inspect per URL (untuk hemat kuota)
   ├─ quota.json                # { "date": "2026-10-25", "used": 412 }
   ├─ perf/
   │   └─ 2026-10-25.json       # snapshot performa per hari run
   └─ runs/
       └─ 2026-10-25T18-00-00.json   # ringkasan run (untuk diff)
```

8.3 Aturan Penyimpanan

- **Tulis atomik:** tulis ke `file.tmp` → `os.Rename`. Mencegah file korup bila proses mati di tengah jalan.
- Setiap JSON diberi field `"schema": 1` untuk migrasi di masa depan.
- Riwayat `runs/` dipangkas otomatis (default simpan 90 run terakhir).
- Satu proses per site pada satu waktu: pakai **lockfile** `data/<site>/.lock` (`os.OpenFile` dengan `O_EXCL`).

> `// ponytail:` Penyimpanan berupa file JSON. Batas: lambat bila > ~50.000 URL atau perlu query ad-hoc. Jalur upgrade: SQLite (`modernc.org/sqlite`, tanpa CGO), `store.go` sudah dibungkus interface kecil.

9. Spesifikasi Modul (Detail)

9.1 Google Auth (`google.go`)

Alur **Service Account** → **JWT** → **Access Token** tanpa library Google.

```
1. Baca sa.json → client_email, private_key (PEM PKCS#8), token_uri
2. Bangun header   : {"alg":"RS256","typ":"JWT"}
3. Bangun claim    : iss=client_email, scope=<scope>, aud=token_uri, iat=now, exp=now+1h
4. Tanda tangan    : RSASSA-PKCS1-v1_5 SHA-256 atas  base64url(header).base64url(claim)
5. POST ke token_uri (form):
      grant_type = urn:ietf:params:oauth:grant-type:jwt-bearer
      assertion  = <jwt>
6. Terima {access_token, expires_in}; cache di memori, refresh 60 detik sebelum habis
```

Scope (prinsip hak minimum):

Perintah	Scope
`inspect` , `perf` , `doctor`	`https://www.googleapis.com/auth/webmasters.readonly`
`submit --gsc`	`https://www.googleapis.com/auth/webmasters`
`submit --google-indexing`	`https://www.googleapis.com/auth/indexing`

Rangka kode (referensi, belum diuji kompilasi):

```
go
type saKey struct {
        ClientEmail string `json:"client_email"`
        PrivateKey  string `json:"private_key"`
        TokenURI    string `json:"token_uri"`
}

type googleClient struct {
        sa    saKey
        http  *http.Client // Timeout wajib, mis. 30s
        mu    sync.Mutex
        cache map[string]cachedToken // key = scope
}

type cachedToken struct {
        val string
        exp time.Time
}

var b64 = base64.RawURLEncoding

func (g *googleClient) token(ctx context.Context, scope string) (string, error) {
        g.mu.Lock()
        defer g.mu.Unlock()
        if t, ok := g.cache[scope]; ok && time.Until(t.exp) > time.Minute {
                return t.val, nil
        }

        now := time.Now()
        claims, _ := json.Marshal(map[string]any{
                "iss": g.sa.ClientEmail, "scope": scope, "aud": g.sa.TokenURI,
                "iat": now.Unix(), "exp": now.Add(time.Hour).Unix(),
        })
        unsigned := b64.EncodeToString([]byte(`{"alg":"RS256","typ":"JWT"}`)) + "." +
b64.EncodeToString(claims)

        block, _ := pem.Decode([]byte(g.sa.PrivateKey))
        if block == nil {
                return "", errors.New("private_key bukan PEM valid")
        }
        k, err := x509.ParsePKCS8PrivateKey(block.Bytes)
        if err != nil {
                return "", err
        }
        rsaKey, ok := k.(*rsa.PrivateKey)
        if !ok {
```

```
                return "", errors.New("private_key bukan RSA")
        }
        sum := sha256.Sum256([]byte(unsigned))
        sig, err := rsa.SignPKCS1v15(rand.Reader, rsaKey, crypto.SHA256, sum[:])
        if err != nil {
                return "", err
        }
        assertion := unsigned + "." + b64.EncodeToString(sig)

        form := url.Values{
                "grant_type": {"urn:ietf:params:oauth:grant-type:jwt-bearer"},
                "assertion":  {assertion},
        }
        req, _ := http.NewRequestWithContext(ctx, "POST", g.sa.TokenURI,
strings.NewReader(form.Encode()))
        req.Header.Set("Content-Type", "application/x-www-form-urlencoded")
        resp, err := g.http.Do(req)
        if err != nil {
                return "", err
        }
        defer resp.Body.Close()
        var out struct {
                AccessToken string `json:"access_token"`
                ExpiresIn   int    `json:"expires_in"`
                Error       string `json:"error_description"`
        }
        if err := json.NewDecoder(resp.Body).Decode(&out); err != nil {
                return "", err
        }
        if out.AccessToken == "" {
                return "", fmt.Errorf("token gagal: %s", out.Error)
        }
        g.cache[scope] = cachedToken{out.AccessToken, now.Add(time.Duration(out.ExpiresIn)
* time.Second)}
        return out.AccessToken, nil
}
```

Helper request (`doJSON`): set header `Authorization: Bearer` , retry dengan *exponential backoff + jitter* untuk status `429` dan `5xx` (maks 4x), hormati `Retry-After` , dan **jangan pernah** me-log header Authorization.

9.2 Sitemap Discovery (`sitemap.go`)

Input: daftar URL sitemap. **Output:** himpunan URL unik.

Aturan	Detail
Sitemap index	Jika root `<sitemapindex>`, ambil semua `<sitemap><loc>` secara rekursif (maks kedalaman 3)
Kompresi	Deteksi `.gz` atau header `Content-Encoding`; pakai `compress/gzip`
Normalisasi URL	Hapus fragment `#...`, lowercase host, buang `:80` / `:443` default, urutkan
Filter	Hanya host yang sama dengan `base_url`. Terapkan `exclude_paths`
Batas	Maks 50.000 URL per sitemap (spesifikasi sitemap), total ikut `max_pages`
Fallback	Jika sitemap tidak ada/kosong dan `--spider`, jalankan spidering (9.3)
Cari otomatis	Jika `sitemaps` kosong: baca `robots.txt` baris `Sitemap:`, lalu coba `/sitemap.xml` dan `/sitemap_index.xml`

```
go
type urlset struct {
        URLs []struct {
                Loc     string `xml:"loc"`
                LastMod string `xml:"lastmod"`
        } `xml:"url"`
}
type sitemapIndex struct {
        Sitemaps []struct {
                Loc string `xml:"loc"`
        } `xml:"sitemap"`
}
```

Fitur selisih (sitemap vs link internal) setelah crawl:

Kondisi	Arti	Tindakan
Ada di sitemap, **tidak** ada link internal masuk (`InternalIn == 0`)	**Orphan page**	Tambahkan internal link
Ada link internal, **tidak** ada di sitemap	Sitemap tidak lengkap	Tambahkan ke sitemap
Ada di sitemap tetapi HTTP ≠ 200	Sitemap kotor	Hapus / perbaiki

9.3 Crawler (`crawl.go`)

Menjawab: "*Apakah semua halaman bisa diakses & dibaca?*"

Worker pool:

```
jobs chan string (URL)  →  N worker (crawl_concurrency)  →  results chan CrawlInfo
```

Aturan	Detail
Concurrency	Default 5. Delay antar request per worker `crawl_delay_ms` (sopan ke server sendiri)
Timeout	`context.WithTimeout` per request (default 20 s)
Redirect	Maks 5. Catat `FinalURL`, dan tandai bila host berubah
Ukuran	Batasi body `io.LimitReader` (default 5 MB)
Content-Type	Hanya proses `text/html` / `application/xhtml+xml`
Header	`User-Agent` dari config, `Accept: text/html`, `Accept-Encoding` ditangani otomatis oleh `net/http`
Retry	1x untuk error jaringan/5xx
Robots.txt	**Dihormati** untuk mode spider (hindari path yang tak boleh). Untuk URL sitemap, cukup dicatat bila terblokir
Spider	BFS dari `base_url`, ikuti `<a href>` internal saja, maks `max_pages`, deduplikasi URL ternormalisasi
Deteksi `ThinHTML`	`WordCount < 50` **dan** ada `<script>` ≥ 3 (atau ada `id="root"`, `id="__next"`, `id="app"` yang hampir kosong)

Hasil per URL: `HTTPStatus`, `FinalURL`, ekstrak (9.3.1), dan daftar link internal untuk menghitung `InternalIn`.

9.3.1 Ekstraksi HTML (`extract.go`)

Lewati isi `<script>`, `<style>`, `<noscript>`, `<template>`.

Elemen	Disimpan sebagai
`<title>`	Zona `title`
`<meta name="description">`	Zona `meta`
`<link rel="canonical">`	`Canonical`
`<meta name="robots">`	`RobotsMeta` (cari `noindex`, `nofollow`)
`<h1>`	Zona `h1`
`<h2>`, `<h3>`	Zona `h2h3`
`<p>`, `<li>`, `<td>`, `<blockquote>`, `<figcaption>`	Zona `body`
`<img alt>`	Zona `alt`; hitung gambar tanpa `alt` (`ImagesNoAlt`)
`<script type="application/ld+json">`	`HasJSONLD` (opsional: baca `@type`)
`<a href>`	Daftar link (internal/eksternal)
Slug URL	Zona `url` (path dipecah per `-`, `_`, `/`)

```go
type Zones struct {
        Title, Meta, URL string
        H1, H2H3, Body, Alt []string
}
```

9.3.2 Aturan Audit On-Page

Kode	Severity	Kondisi
`http_not_200`	error	Status ≠ 200
`noindex_meta`	error	`robots` meta memuat `noindex`
`title_missing`	error	Tidak ada `<title>`
`title_length`	warn	< 30 atau > 60 karakter
`meta_missing`	warn	Tidak ada meta description
`meta_length`	warn	< 70 atau > 160 karakter
`h1_missing`	error	Tidak ada H1
`h1_multiple`	warn	H1 > 1
`canonical_missing`	warn	Tidak ada canonical
`canonical_mismatch`	warn	Canonical ke URL lain (dan bukan dirinya)
`images_no_alt`	warn	Ada gambar tanpa `alt`
`thin_content`	warn	`WordCount < 300` (blog)
`thin_html_spa`	info	`ThinHTML` true (kemungkinan JS-rendered, hasil analisis kata tidak dapat dipercaya)
`jsonld_missing`	info	Tidak ada JSON-LD
`orphan_page`	warn	Ada di sitemap tapi `InternalIn == 0`
`title duplicate` / `meta_duplicate`	warn	Judul/deskripsi sama dengan halaman lain

Ambang batas disimpan sebagai konstanta di satu tempat supaya mudah diubah.

9.4 Inspector (`inspect.go` + `gsc.go`)

Menjawab: "*Apakah di-crawl? Apakah ter-index?*"

Endpoint

```
POST https://searchconsole.googleapis.com/v1/urlInspection/index:inspect
Body: {"inspectionUrl":"<url>", "siteUrl":"<gsc_property>", "languageCode":"id-ID"}
```

Respons (field yang dipakai): `inspectionResult.indexStatusResult` → `verdict`, `coverageState`, `robotsTxtState`, `indexingState`, `lastCrawlTime`, `pageFetchState`, `googleCanonical`, `userCanonical`, `crawledAs`.

Pemetaan Status (urutan prioritas)

Cek (berurutan)	`IndexStatus`
`robotsTxtState == "DISALLOWED"` atau `indexingState` memuat `BLOCKED_*`	`blocked`
`pageFetchState` ∈ { `NOT_FOUND`, `SOFT_404`, `SERVER_ERROR`, `REDIRECT_ERROR`, `ACCESS_DENIED`, `ACCESS_FORBIDDEN`, `BLOCKED_4XX`, `INTERNAL_CRAWL_ERROR`, `INVALID_URL` }	`error`
`verdict == "PASS"`	`indexed`
`coverageState` memuat `"Crawled - currently not indexed"`	`crawled_not_indexed`
`coverageState` memuat `"Discovered - currently not indexed"`	`discovered_not_indexed`
`coverageState` memuat `"unknown to Google"`	`unknown_to_google`
`coverageState` memuat `"Duplicate"` atau `"canonical"`	`duplicate`
selain itu	`other` (tampilkan `RawCoverage` apa adanya)

> Karena `coverageState` adalah teks bebas, `RawCoverage` **selalu disimpan dan ditampilkan** di laporan detail supaya tidak ada informasi yang hilang bila wording berubah.

Penjadwal Hemat Kuota

Masalah: situs 1.200 halaman × inspeksi mingguan > kuota 2.000/hari bila tidak dirotasi.

Algoritme pemilihan antrian (urut prioritas):

1. URL **belum pernah** diinspeksi (`never_inspected`).
2. URL yang cocok `priority_paths` (blog, beranda).
3. URL berstatus **bermasalah** terakhir kali (`crawled_not_indexed`, `discovered_not_indexed`, `unknown_to_google`, `error`), dicek ulang lebih sering.
4. URL `indexed` yang usia inspeksinya > `reinspect_after_days`.
5. Sisanya, yang paling lama tidak dicek.

Potong sampai `min(inspect_daily_budget - quota_terpakai_hari_ini, --limit)`.

Rate limit: `time.Ticker` dengan interval `60s / inspect_rpm` + worker 3–5. Pada `429`, berhenti sementara (backoff) dan **jangan** mencoba lagi sampai interval berikutnya.

Penghitung kuota: `quota.json` berisi `{date, used}` (tanggal zona **Pacific Time**, karena kuota Google reset mengikuti hari Pacific). Di-increment per request sukses/gagal yang menghabiskan kuota.

> `// ponytail:` Kuota dilacak lokal di `quota.json`. Batas: tidak tahu bila Anda juga memakai kuota dari tool lain pada properti yang sama. Jalur upgrade: baca header kuota/error `429` sebagai sumber kebenaran (sudah ada fallback: berhenti saat `429`).

9.5 Performance Fetcher (`gsc.go`)

Menjawab: "*Tayang di halaman 1? Kata apa? Berapa klik?*"

Endpoint

```
POST
https://www.googleapis.com/webmasters/v3/sites/{urlencode(gsc_property)}/searchAnalytics/qu
ery
Body:
{
  "startDate": "YYYY-MM-DD",
  "endDate":   "YYYY-MM-DD",
  "dimensions": ["page","query"],
  "rowLimit": 25000,
  "startRow": 0,
  "dataState": "final"
}
```

Aturan	Detail
Rentang tanggal	`endDate = hari ini − 3` (data final tertunda), `startDate = endDate − perf_days + 1`
Paginasi	Ulangi dengan `startRow += 25000` sampai baris < `rowLimit`
Urut respons	Google mengurutkan berdasarkan clicks menurun
Format kunci	`keys[0]` = URL halaman, `keys[1]` = query
Agregasi per halaman	Hitung dari baris `page×query` : `clicks`, `impressions` dijumlahkan; `position` = **rata-rata berbobot impresi**; `ctr = clicks/impressions`
`Page1`	`position_page ≤ 10.0` (pendekatan; tampilkan angka aslinya)
Pencocokan URL	Normalisasi sama seperti 9.2 (trailing slash, fragment) supaya `Page` bisa digabung
Kueri anonim	Dicatat di laporan sebagai catatan: "*query dengan volume sangat kecil tidak ditampilkan Google*"

Perbandingan periode (opsional, murah): jalankan 2 kali (periode sekarang vs sebelumnya) → tampilkan delta clicks/impressions/posisi per halaman (`▲ ▼`).

```
go
type saRow struct {
        Keys        []string `json:"keys"`
        Clicks      float64  `json:"clicks"`
        Impressions float64  `json:"impressions"`
        CTR         float64  `json:"ctr"`
        Position    float64  `json:"position"`
}
```

9.6 Keyword Gap Analyzer (`analyze.go`)

Menjawab: "*Kata yang diketik orang di Google, ada di teks halamanmu atau tidak?*"

Normalisasi

1. Lowercase (`strings.ToLower`).
2. Pisah token dengan `strings.FieldsFunc(s, func(r rune) bool { return !unicode.IsLetter(r) && !unicode.IsDigit(r) })`.
3. Buang token 1 karakter.

4. Stopword **tidak dihitung sebagai kata hilang**, tapi tetap dipakai untuk pencocokan frasa. Daftar kecil di-embed (ID: `yang, di, ke, dari, dan, atau, untuk, dengan, pada, ini, itu, adalah, cara`; EN: `the, a, an, of, to, in, for, and, or, is, how`).

Level Pencocokan (per query vs satu halaman)

Level	Syarat	Arti
`exact`	Frasa query (token berurutan) ditemukan di salah satu zona	Halaman sudah memuat frasa persis
`all_words`	Semua token non-stopword ada di halaman, tetapi tersebar	Kata ada, frasa belum berbentuk utuh
`partial`	Sebagian token ada. Token yang hilang disimpan di `MissingTok`	Tambah kata yang hilang
`absent`	Tidak ada token non-stopword yang ditemukan	Google mengaitkan halaman lewat sinyal lain

Pencarian frasa: gabungkan token tiap zona dengan spasi, lalu cek `strings.Contains(" "+zoneText+" ", " "+queryNorm+" ")`.

`FoundIn` mencatat zona mana saja yang memuat (urutan kekuatan: `title` > `h1` > `h2h3` > `meta` > `url` > `body` > `alt`).

Skor Peluang (Opportunity Score)

Heuristik sederhana, bukan sihir. Konstanta dapat diubah di satu tempat.

```
expectedCTR(pos) ≈ {1:0.28, 2:0.15, 3:0.11, 4:0.08, 5:0.07, 6:0.05, 7:0.04, 8:0.035,
9:0.03, 10:0.025, 11-20:0.01, >20:0.003}

potensiKlik = impressions × max(0, expectedCTR(posisi_target) − ctr_aktual)

score = potensiKlik × bobotMatch
bobotMatch: absent=1.0 | partial=0.9 | all_words=0.6 | exact=0.3
```

Dengan `posisi_target = max(1, posisi − 3)` (andaikan naik 3 peringkat).

Kategori hasil:

Kategori	Kriteria	Tindakan yang disarankan
⚡ **Low-hanging fruit**	posisi 5–20, impresi tinggi (≥ `--min-impressions`), `match` ≠ `exact`	Sisipkan frasa di H1/H2/paragraf pertama
🎯 **Title/Meta fix**	posisi ≤ 10, CTR jauh di bawah `expectedCTR`	Perbaiki judul dan meta description
✅ **Sudah kuat**	posisi ≤ 10 dan `match == exact`	Pertahankan
🔎 **Konten belum menjawab**	`absent`, impresi besar	Pertimbangkan section / artikel baru

> `// ponytail:` Pencocokan kata memakai kecocokan harfiah (tanpa stemming). Batas: "membuat" ≠ "buat", "running" ≠ "run". Jalur upgrade: suffix stripper kecil untuk Indonesia/Inggris (~80 baris) atau stemmer Porter.

9.7 Submitter (`gsc.go`, `indexnow.go`)

9.7.1 Sitemap ke GSC

```
PUT  https://www.googleapis.com/webmasters/v3/sites/{site}/sitemaps/{feedpath}
GET  https://www.googleapis.com/webmasters/v3/sites                          # doctor: cek akses
GET  https://www.googleapis.com/webmasters/v3/sites/{site}/sitemaps          # status sitemap
```

(`{site}` dan `{feedpath}` di-**URL-encode** penuh.) Sukses = `204` / `200`.

`seo-boost submit --gsc` mengirim ulang sitemap. Tool juga membaca `sitemaps.list` untuk menampilkan: `lastDownloaded`, `isPending`, `errors`, `warnings`, jumlah URL yang dikirim vs ter-index (jika tersedia).

> Pengiriman ulang sitemap itu **sinyal**, bukan perintah. Google tetap menjadwalkan crawl sendiri. Yang berpengaruh nyata: `<lastmod>` akurat di sitemap dan internal link yang baik.

9.7.2 IndexNow (Bing, Yandex, dkk. — bukan Google)

```
POST https://api.indexnow.org/indexnow
Content-Type: application/json
{
  "host": "example.com",
  "key": "<indexnow_key>",
  "keyLocation": "https://example.com/<indexnow_key>.txt",
  "urlList": ["https://example.com/blog/artikel-baru", "..."]
}
```

Aturan	Detail
Kunci	Hex 8–128 karakter. Perintah `seo-boost indexnow-key` membuat kunci acak (`crypto/rand`) dan mencetak isi file yang harus ditaruh di `https://domain/<key>.txt`
Batas	Maks 10.000 URL per request
URL yang dikirim	Hanya URL **baru/berubah** sejak run terakhir (bandingkan `lastmod` atau hash konten dari `store`)
Validasi	Sebelum submit, tool memeriksa file kunci bisa diakses (`GET keyLocation` harus mengembalikan isi = kunci). Gagal = batalkan dan beri pesan jelas
Respons	`200` / `202` = diterima. `422` / `403` = kunci tidak valid

9.7.3 Google Indexing API (OPSIONAL, mati secara default)

Inilah yang sebenarnya dipakai fitur "Instant Indexing" di plugin WordPress seperti Rank Math. Pengguna plugin tidak membuka GSC karena plugin memanggil API ini lewat service account.

> WARNING
>
> **Status resmi:** Google menyatakan Indexing API hanya untuk halaman `JobPosting` dan `BroadcastEvent` (livestream). Untuk blog/portofolio biasa, ini **di luar penggunaan yang didukung**. API tetap menerima request (tidak ditolak secara teknis), tetapi:
>
> - Google tidak menjanjikan URL akan dicrawl cepat atau di-index.
> - Bukti efektivitas untuk konten biasa hanya laporan komunitas dan hasilnya campuran, bukan data resmi.
> - Google bisa membatasi atau menghentikan perilaku ini kapan saja tanpa pemberitahuan.
> - Tidak ada dokumentasi resmi soal hukuman, tetapi memakainya di luar peruntukan adalah risiko kebijakan yang kamu tanggung sendiri.

> Karena itu fitur ini **opt-in**: tidak jalan kecuali diaktifkan eksplisit.

Endpoint

```
POST https://indexing.googleapis.com/v3/urlNotifications:publish
Body: {"url": "https://example.com/blog/artikel-baru", "type": "URL_UPDATED"}   # atau
URL_DELETED
GET  https://indexing.googleapis.com/v3/urlNotifications/metadata?url=<urlencoded>   #
status notifikasi terakhir
```

Aspek	Detail
Biaya	Gratis. Tidak butuh billing
Setup tambahan	Enable **"Web Search Indexing API"** di project Google Cloud yang sama
Scope	`https://www.googleapis.com/auth/indexing`
Izin di GSC	Service account harus **Owner** properti (bukan sekadar Full/Restricted)
Kuota default	**200 request publish/hari**, 180/menit (bisa dinaikkan lewat form permintaan Google)
Batch	Didukung (maks 100 URL/batch), tetapi tiap URL tetap menghabiskan kuota

Perilaku tool (aman secara desain):

1. Aktif hanya jika `"google_indexing": {"enabled": true}` di config **dan** flag `--google-indexing` diberikan. Dua kunci, supaya tidak jalan tanpa sengaja.
2. Tool mencetak peringatan di atas sekali per run dan mencatat di laporan.
3. Hanya kirim URL **baru atau berubah** sejak run terakhir (bandingkan `lastmod` / hash konten). Jangan pernah mengirim seluruh situs.
4. Hanya URL berstatus HTTP 200, tanpa `noindex`, dan bukan duplikat/redirect (hasil crawl sudah tahu).
5. Dibatasi `daily_cap` (default **50**, jauh di bawah kuota 200) dan dilacak di `quota.json`.
6. Hasil `getMetadata` dan status HTTP dicatat per URL. Tool **tidak** mengklaim "sudah ter-index"; status index tetap dikonfirmasi lewat Inspector (9.4) beberapa hari kemudian.
7. Pada `403`, tool berhenti dan menjelaskan: kemungkinan bukan Owner, API belum di-enable, atau Google membatasi akses.

```
json
"google_indexing": { "enabled": false, "daily_cap": 50 }
```

> `// ponytail:` Memakai Indexing API di luar peruntukan resmi untuk situs non-loker/non-livestream. Batas: dapat berhenti bekerja atau dibatasi Google kapan saja, dan efeknya tidak terjamin. Jalur aman: sitemap dengan `<lastmod>` akurat + internal link + IndexNow (untuk Bing/Yandex).

Cara mengukur apakah fitur ini membantu situs kamu (tanpa asumsi): tool mencatat `selisih waktu` antara URL dikirim ke API dan `lastCrawlTime` pertama yang lebih baru dari waktu kirim (dari Inspector). Setelah beberapa artikel, kamu punya data sendiri: apakah crawl memang lebih cepat dibanding artikel yang tidak dikirim.

9.8 Reporter (`report.go`)

Format	Penggunaan
`text`	Terminal, pakai `tabwriter`, ikon ✅ ⚠️ ❌ ⚡ (dimatikan otomatis bila bukan TTY / `NO_COLOR`)
`json`	Mesin / integrasi / CI
`md`	Disimpan, di-commit, atau dikirim ke Notion/issue
`html`	Satu file mandiri (CSS inline), bisa dibuka dari mana saja

Struktur laporan:

1. **Ringkasan** (angka): total halaman, ter-index (n/N), bermasalah, tayang halaman 1, total klik/impresi, perubahan vs run sebelumnya.
2. **Tabel status halaman** (urut: bermasalah di atas).
3. **Halaman 1 Google** (halaman, posisi, klik).
4. **Peluang boost** (keyword gap teratas, global dan per halaman).
5. **Audit on-page** (dikelompokkan per severity).
6. **Selisih sitemap vs link internal** (orphan, tidak di sitemap).
7. **Perubahan sejak run terakhir (diff):** halaman baru ter-index, halaman yang turun/hilang dari index, kenaikan/penurunan posisi ≥ 3.
8. **Catatan & batasan data** (otomatis, ringkas, ambil dari bagian 1.3).

Diff: bandingkan `runs/<terbaru>` dengan `runs/<sebelumnya>`, kunci = URL. Hanya tampilkan perubahan bermakna.

9.9 Web UI Lokal (`serve.go` , `web/index.html`) — Phase 3

Aspek	Keputusan
Bind	`127.0.0.1` **saja** secara default
Teknologi	`embed` satu `index.html` + `html/template` + sedikit JS vanilla. Tanpa npm, tanpa bundler
Auth	Token acak dicetak saat start (`?t=...` / header). Wajib bila `--addr` bukan loopback
Endpoint	`GET /` dashboard · `GET /api/sites` · `GET /api/sites/{name}/pages` · `GET /api/sites/{name}/gaps` · `POST /api/sites/{name}/run` · `GET /api/runs/{id}`
Run async	Goroutine + status polling (`/api/runs/{id}` mengembalikan progres: n/N URL)
Halaman	(1) Ringkasan semua site (2) Tabel halaman dengan filter status (3) Detail halaman: audit + keyword gap (4) Riwayat run & diff
Keamanan	Tidak ada endpoint yang menerima URL bebas dari pengguna (mencegah SSRF). Hanya situs di config

9.10 Notifier (`notify.go`) — Phase 3

Kanal	Cara	Biaya
Telegram	`POST https://api.telegram.org/bot<TOKEN>/sendMessage` (`chat_id` , `text` , `parse_mode`)	Gratis
Discord	`POST <webhook_url>` JSON `{"content": "..."}`	Gratis
Email	Tidak dibuat (SMTP butuh kredensial; Ponytail: tunda)	–

Kirim **ringkasan + diff** saja (maks ~1.500 karakter), bukan laporan penuh. Kirim hanya bila ada perubahan bermakna atau `--notify always` .

9.11 Log Server (Opsional, Phase 4) — Googlebot Crawl Tanpa Kuota

Cara lain menjawab "*apakah Googlebot benar-benar mengunjungi semua halaman?*" tanpa batas 2.000/hari: parsing **access log** (Nginx/Apache/Caddy).

- Baca log (flag `--log path` , format *combined*).

- Filter User-Agent `Googlebot`, lalu **verifikasi** dengan reverse DNS (`net.LookupAddr` harus berakhiran `.googlebot.com` / `.google.com`, lalu forward-lookup harus cocok). UA saja bisa dipalsukan.
- Hasil: tanggal terakhir Googlebot mengunjungi tiap path, frekuensi, dan status HTTP yang diterimanya.
- Hanya tersedia jika kamu punya akses log server (tidak untuk hosting statis seperti GitHub Pages/Vercel).

10. Contoh Output

```
text
═══════════════════════════════════════════════════════════════
 SEO-BOOST · portfolio (sc-domain:example.com) · 2026-10-25 18:00
═══════════════════════════════════════════════════════════════

 RINGKASAN
   Halaman ditemukan   : 14   (sitemap: 14 | link internal: 13)
   Ter-index Google    : 12/14
   Bermasalah          : 2    (1 crawled-not-indexed, 1 discovered-not-indexed)
   Tayang di Halaman 1 : 5 halaman (posisi rata-rata ≤ 10)
   28 hari terakhir    : 1.842 klik · 61.240 impresi · CTR 3,0%
   Kuota inspeksi      : 14 terpakai hari ini (sisa 1.786)

 STATUS CRAWL & INDEX
 ✅ /                        indexed  crawl 2 jam lalu   Hal.1 (pos 1,2)   312 klik
 ✅ /blog/belajar-golang     indexed  crawl 3 hari lalu  Hal.1 (pos 4,5)    48 klik
 ⚠️  /blog/tips-docker        crawled - currently not indexed (crawl 5 hari lalu)
 ❌ /project/kalkulator-kpr  discovered - currently not indexed (belum di-crawl)

 DETAIL: /blog/belajar-golang
   Tayang           : 1.420 impresi · 48 klik · CTR 3,4% · pos rata-rata 4,5
   Audit            : ✓ title 54 kar. · ✓ meta 148 kar. · ⚠ 2 gambar tanpa alt
   Query & kecocokan:
    1. "tutorial golang pemula"   pos 3,0  exact      [h1, body]            ✅
    2. "cara install go"          pos 8,2  exact      [h2h3]                ✅
    3. "golang concurrency contoh" pos 12,1 210 impresi  absent   PELUANG
         → tambahkan frasa ini di H2 + paragraf penjelasan
    4. "belajar goroutine"         pos 9,4  partial    hilang: [goroutine]    PELUANG

 DIFF vs RUN 2026-10-18
   + /blog/panduan-git    baru ter-index
   ▼ /blog/tips-docker    pos 7,1 → 11,4 (turun keluar halaman 1)

 CATATAN: posisi = rata-rata di GSC; data tertunda ±3 hari; query langka tidak ditampilkan.
```

11. Keamanan

Risiko	Mitigasi
Kebocoran `sa.json`	Folder `secrets/` masuk `.gitignore`. Di Windows, batasi ACL file. Di Linux `chmod 600`. Di CI gunakan *secret* bukan file di repo
Secret di config	Token Telegram/Discord hanya via env var
Scope berlebih	Default `webmasters.readonly`, scope penuh hanya saat `submit --gsc`
Log bocor token	Jangan log header `Authorization` atau isi respons token. Redaksi pada `slog`
SSRF di mode `serve`	Tool hanya mengakses host yang ada di config. Tidak ada input URL bebas
Web UI terbuka ke jaringan	Default bind `127.0.0.1`. Non-loopback wajib token
Crawler membebani situs	Concurrency kecil, delay, hormati robots.txt pada mode spider
Kerentanan dependency	Hanya 1 dependency. `go mod vendor`, `govulncheck`, update `x/net` berkala
Supply-chain build	`go build -trimpath`, simpan `go.sum`, hindari `go install` tool acak di pipeline rilis
Path traversal nama site	Validasi `[a-z0-9-_]` karena dipakai sebagai nama folder
Penulisan file korup	Tulis atomik (tmp + rename)
Respons hostile dari website	`io.LimitReader`, timeout, batas kedalaman redirect, batasi ukuran sitemap yang didekompresi

12. Strategi Testing

Level	Isi	Cara
Unit	Normalisasi URL, parser sitemap (urlset, index, gz), ekstraksi HTML (fixture), tokenizer, `matchLevel`, skor peluang, pemetaan `IndexStatus`, agregasi posisi berbobot	`testing` + tabel kasus + `testdata/`
Kontrak API	Respons **nyata yang telah dianonimkan** dari Google disimpan di `testdata/` untuk menguji parsing	`httptest.Server` meniru Google
Auth	JWT: header/claim benar, tanda tangan terverifikasi dengan public key dari key uji	Buat RSA key sementara di test
Integrasi	`run` end-to-end terhadap website uji lokal (`httptest`) + mock GSC	`go test ./...`
Kuota	Penjadwal tidak melebihi budget, urutan prioritas benar, reset harian	Test dengan jam palsu (fungsi `now` bisa disuntik)
Ketahanan	HTML rusak, sitemap raksasa, redirect loop, timeout	Fixture + `httptest` yang sengaja lambat
Statik	`go vet ./...` , `staticcheck` (opsional), `govulncheck ./...`	Dijalankan di CI
Race	`go test -race ./...`	Penting untuk worker pool

Kriteria selesai tiap modul: test hijau + `go vet` bersih + `-race` bersih.

13. Build & Distribusi

```
powershell
# Build lokal (Windows)
go build -trimpath -ldflags "-s -w -X main.version=1.0.0" -o seo-boost.exe .

# Cross-compile
$env:GOOS="linux";   $env:GOARCH="amd64"; go build -trimpath -ldflags "-s -w" -o dist/seo-boost-linux-amd64 .
$env:GOOS="linux";   $env:GOARCH="arm64"; go build -trimpath -ldflags "-s -w" -o dist/seo-boost-linux-arm64 .
$env:GOOS="darwin";  $env:GOARCH="arm64"; go build -trimpath -ldflags "-s -w" -o dist/seo-boost-darwin-arm64 .
$env:GOOS="windows"; $env:GOARCH="amd64"; go build -trimpath -ldflags "-s -w" -o dist/seo-boost-windows-amd64.exe .
```

- `CGO_ENABLED=0` (default untuk stdlib murni) → binary statis, tanpa dependensi sistem.
- Sertakan checksum `sha256` untuk tiap binary rilis.
- `main.version` diisi lewat `-ldflags -X`.

Inisialisasi project:

```
powershell
mkdir seo-boost; cd seo-boost
go mod init seo-boost
go get golang.org/x/net@latest
go mod vendor
```

14. Otomasi / Scheduling

Tool **tidak** memuat penjadwal sendiri (Ponytail). Pakai yang sudah ada di OS atau CI.

14.1 Windows Task Scheduler (tiap Senin 07:00)

```
powershell
schtasks /Create /SC WEEKLY /D MON /ST 07:00 /TN "seo-boost" `
  /TR "C:\tools\seo-boost\seo-boost.exe run --site all --format md --out C:\tools\seo-boost\reports\latest.md --notify"
```

14.2 Linux cron

```
cron
0 7 * * 1  cd /opt/seo-boost && ./seo-boost run --site all --format md --out
reports/latest.md --notify
```

14.3 GitHub Actions (`.github/workflows/seo.yml`)

```
yaml
name: seo-boost
on:
  schedule: [{ cron: "0 0 * * 1" }]   # Senin 07:00 WIB
  workflow_dispatch: {}
jobs:
  run:
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v4
      - uses: actions/setup-go@v5
        with: { go-version: "1.22" }
      - run: go build -trimpath -ldflags "-s -w" -o seo-boost .
      - run: |
          mkdir -p secrets
          echo '${{ secrets.GSC_SA_JSON }}' > secrets/sa.json
      - uses: actions/cache@v4
        with:
          path: data
          key: seoboost-data-${{ github.run_id }}
          restore-keys: seoboost-data-
      - run: ./seo-boost run --site all --format md --out report.md --notify
        env:
          SEOBOOST_TG_TOKEN: ${{ secrets.SEOBOOST_TG_TOKEN }}
      - uses: actions/upload-artifact@v4
        with: { name: seo-report, path: report.md }
```

> Folder `data/` di-cache supaya diff antar run dan penghitung kuota tetap ada. Jika cache hilang, tool otomatis memulai dari nol, tidak ada yang rusak.

14.4 Pemicu Setelah Publish Artikel Baru

Tambahkan satu langkah di pipeline deploy website: `seo-boost submit --site portfolio --gsc --indexnow`. Cukup 1 baris, tanpa mengubah kode website.

15. Roadmap & Checklist per Fase

> Estimasi kasar untuk 1 developer. Tiap fase menghasilkan sesuatu yang **sudah berguna**.

Fase 0 — Fondasi (±0,5 hari)

- Install Go 1.22+, `go mod init`, tambah `x/net`, `go mod vendor`
- Setup Google Cloud + Service Account + tambah ke GSC (bagian 2)
- `config.go`: load + validasi
- `main.go`: dispatch subcommand, `version`, flag global, `slog`

Selesai bila: `seo-boost version` dan validasi config berjalan.

Fase 1 — Inti (MVP) (±5–7 hari)

- `google.go`: JWT RS256 + token cache + `doJSON` (retry/backoff)
- `doctor`: cek `sites.list` dan izin tiap properti
- `sitemap.go`: parse urlset/index/gz + auto-discovery
- `crawl.go` + `extract.go`: worker pool + ekstraksi + audit
- `inspect.go`: pemetaan status + penjadwal kuota + `quota.json`
- `perf` (searchAnalytics + paginasi + agregasi)
- `analyze.go`: tokenizer, `matchLevel`, skor peluang
- `store.go`: JSON atomik + lockfile
- `report.go`: format `text` + `json`
- Test unit semua modul di atas

Selesai bila: `seo-boost run --site portfolio` pada situs sungguhan menampilkan laporan seperti bagian 10.

Fase 2 — Otomasi & Riwayat (±2–3 hari)

- `submit --gsc` + status sitemap

- `indexnow-key` + `submit --indexnow` (dengan verifikasi file kunci)
- Riwayat `runs/` + `report --diff`
- Format `md` dan `html`
- Exit code + `--fail-on-issues`
- Contoh Task Scheduler, cron, GitHub Actions

Selesai bila: laporan mingguan otomatis berjalan dan menampilkan perubahan.

Fase 3 — Kenyamanan (±3–4 hari)

- `serve` + `web/index.html` (dashboard, filter, detail)
- `notify.go` (Telegram/Discord)
- Perbandingan periode di `perf` (delta ▲▼)

Selesai bila: dashboard lokal bisa memicu run dan menampilkan hasil.

Fase 4 — Opsional / Saat Dibutuhkan

- Parser access log + verifikasi Googlebot (9.11)
- Stemming ID/EN sederhana
- Backend SQLite bila data besar
- Pecah ke `internal/` bila kode > ~3.000 baris
- Render JS opsional (memanggil Chrome yang sudah terpasang via flag, bukan dependency)

16. Ponytail Debt Ledger

Penyederhanaan yang disengaja, beserta batas dan jalur upgrade.

#	Penyederhanaan	Batas (ceiling)	Jalur upgrade
1	Struktur datar `package main`	Mulai berantakan > ~3.000 baris	Pecah ke `internal/{google,crawl,analyze,store,report}`
2	Penyimpanan JSON file	Lambat > ~50.000 URL, tanpa query ad-hoc	SQLite via `modernc.org/sqlite` (tanpa CGO) di balik interface `Store`
3	1 dependency `x/net/html`	Tetap kode pihak luar	Tokenizer HTML buatan sendiri (~150 baris)
4	Pencocokan kata harfiah	Tidak paham imbuhan/sinonim	Suffix stripper atau stemmer
5	Crawler HTML mentah	SPA/JS-rendered terbaca tipis	Render via Chrome headless eksternal (opsional)
6	Kuota dilacak lokal	Tak tahu penggunaan dari tool lain	Jadikan `429` sebagai kebenaran (sudah menjadi fallback)
7	CTR yang diharapkan = tabel tetap	Kurva CTR tiap niche berbeda	Hitung kurva dari data GSC situs sendiri
8	Tanpa penjadwal internal	Perlu cron/Task Scheduler/CI	Subcommand `daemon` dengan `time.Ticker`
9	Posisi "Halaman 1" = rata-rata ≤ 10	Bukan posisi pasti per pencarian	Tampilkan sebaran per `device` / `country` (tambah dimensi)
10	Notifikasi hanya Telegram/Discord	Tidak ada email	SMTP via `net/smtp` bila dibutuhkan
11	Tanpa multi-user / login UI	Tool pribadi	Reverse proxy dengan auth di depannya

Setiap kompromi ini ditandai di kode dengan komentar `// ponytail: <batas> → <jalur upgrade>`, sehingga mudah dikumpulkan lagi.

17. Troubleshooting & FAQ

Gejala	Penyebab umum	Solusi
`403 User does not have sufficient permission for site`	Service account belum ditambahkan ke GSC, atau format `gsc_property` salah	Tambahkan `client_email` di GSC → Users. Cek `sc-domain:` vs URL-prefix + trailing slash
`403 Search Console API has not been used in project`	API belum di-Enable	Enable "Google Search Console API" di project yang sama dengan service account
`400 invalid_grant` / `Invalid JWT Signature`	`private_key` rusak (newline `\n` hilang) atau jam sistem salah	Pakai file JSON asli. Sinkronkan jam
`429 Quota exceeded` pada inspect	Melewati 600/menit atau 2.000/hari	Turunkan `inspect_rpm` /budget. Tunggu reset (zona Pacific)
Data `perf` kosong	Properti baru / belum ada impresi / tanggal terlalu baru	Tunggu data. Gunakan rentang lebih panjang. Data tertunda ±3 hari
URL ada di sitemap tapi `unknown_to_google`	Google belum menemukan, atau sitemap belum diproses	Cek status sitemap, perbaiki internal link, tunggu
`crawled_not_indexed` banyak	Konten tipis/duplikat/kualitas rendah menurut Google	Tambah nilai unik, perbaiki internal link, hapus halaman tak berguna
Keyword gap bilang `absent` padahal kata ada	Halaman dirender JS (`thin_html_spa`)	Lihat peringatan, pertimbangkan SSR/prerender
IndexNow `403`	File kunci tidak bisa diakses publik / isi tidak cocok	Pastikan `https://domain/<key>.txt` berisi tepat kunci

FAQ singkat

- **Apakah ini benar-benar gratis?** Ya. Search Console API tidak berbayar dan tidak memerlukan billing. IndexNow gratis. Telegram/Discord webhook gratis.
- **Bisa untuk situs orang lain?** Hanya jika kamu punya akses di GSC situs itu.
- **Apakah bisa menjamin tayang di halaman 1?** Tidak. Tool ini **mengukur dan memberi rekomendasi berbasis data**, bukan menjamin peringkat.
- **Universal untuk semua bahasa/framework?** Ya, tool bekerja dari luar via URL/HTML/sitemap. Satu pengecualian: halaman yang isinya dirender JS memberi analisis kata yang kurang akurat.
- **Kenapa tidak pakai Indexing API?** Google membatasi resminya untuk `JobPosting` dan `BroadcastEvent` .

18. Lampiran: Referensi API

Fungsi	Method & URL	Scope	Kuota/Catatan
Token	`POST {token_uri}` (`https://oauth2.googleapis.com/token`)	–	JWT bearer grant
Daftar properti	`GET https://www.googleapis.com/webmasters/v3/sites`	readonly	Dipakai `doctor`
Inspect URL	`POST https://searchconsole.googleapis.com/v1/urlInspection/index:inspect`	readonly	2.000/hari, 600/menit per properti
Search Analytics	`POST https://www.googleapis.com/webmasters/v3/sites/{site}/searchAnalytics/query`	readonly	Maks 25.000 baris/request, riwayat 16 bulan
Daftar sitemap	`GET https://www.googleapis.com/webmasters/v3/sites/{site}/sitemaps`	readonly	Status, error, warning
Submit sitemap	`PUT https://www.googleapis.com/webmasters/v3/sites/{site}/sitemaps/{feedpath}`	webmasters (penuh)	Perlu izin Full/Owner
IndexNow	`POST https://api.indexnow.org/indexnow`	–	Maks 10.000 URL/request; tanpa Google
Indexing API (opsional)	`POST https://indexing.googleapis.com/v3/urlNotifications:publish`	indexing	200/hari default; resmi hanya JobPosting/BroadcastEvent

Glosarium

Istilah	Arti
GSC	Google Search Console
Crawl	Googlebot mengunjungi/mengunduh halaman
Index	Halaman disimpan di basis data Google dan boleh muncul di hasil pencarian
Impression	Link muncul di hasil pencarian yang dilihat pengguna
CTR	Clicks ÷ Impressions
Position	Posisi rata-rata di hasil pencarian (1 = teratas)
Orphan page	Halaman tanpa link internal yang menunjuk ke sana
Keyword gap	Selisih antara kata yang dicari orang dan kata yang ada di halaman
Service Account	Akun robot Google untuk akses API tanpa login manusia

*Dokumen ini adalah blueprint. Potongan kode berupa kerangka referensi dan belum dikompilasi atau diuji. Langkah berikutnya adalah mengerjakan **Fase 0** → **Fase 1**.*